A3 LABORATORIO CLÍNICO VETERINARIO · DOCUMENTO OPERATIVO

Estimado de costos para levantar y mantener la plataforma

Inventario de servicios a contratar a nombre de A3, modelo o tecnología de cada capa, y rango de gasto mensual de mantenimiento. A3 paga cada factura; N3 configura y opera.

Fecha
14 de septiembre de 2026

Moneda de las facturas
USD (la mayoría) y COP (Alegra)

Audiencia
Dirección A3 · caja y contratación

1. El acuerdo de caja

La plataforma no es un solo software: es un conjunto de cuentas. Cada una emite su propia factura. Para no mezclar caja ni depender de que N3 adelante pagos:

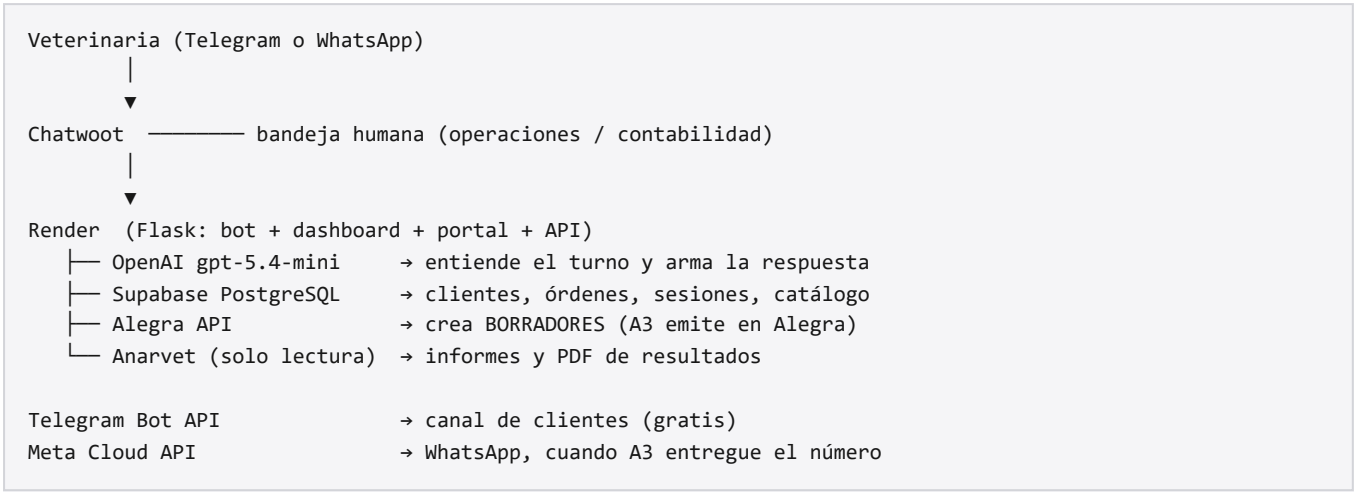
> **Regla:** A3 abre cada cuenta con correo corporativo y tarjeta de A3, paga la factura y entrega a N3 acceso de colaborador (no de titular de facturación). N3 no intermedia cobros de infraestructura.

Este documento usa precios públicos vigentes a septiembre de 2026. El tipo de cambio COP/USD varía; la conversión a pesos es **orientativa a COP 4.000 por USD**. El valor real lo define el extracto de la tarjeta o el banco.

Alcance cubierto: bot (Telegram y, cuando exista, WhatsApp), bandeja Chatwoot, dashboard operativo, portal de clientes, espejo de resultados Anarvet con PDF, y borradores de factura en Alegra. Fuera de este presupuesto: emisión DIAN automatizada, pasarela de pago, y la licencia de Anarvet (ya es de A3).

2. Mapa de la plataforma

Así se conectan las piezas en producción. Lo único que el cliente de la veterinaria ve es Telegram o WhatsApp, el portal, y los avisos. El resto es interno.



En desarrollo local se usa ngrok para exponer el Flask del computador. **En producción ngrok no se usa ni se paga:** Render es la URL pública.

3. Qué “modelo” usa cada parte

Hay un solo modelo de inteligencia artificial. El resto son plataformas, APIs y código determinístico (reglas fijas, no IA).

Capa / parte	Plataforma	Motor / modelo	Qué hace
Agente conversacional	OpenAI API	**gpt-5.4-mini**	Lee el mensaje, clasifica intención y propone el texto. Guardrails en Python corrigen y cierran la orden.
Formato de respuesta	OpenAI Structured Outputs	JSON schema fijo (`app/schema.py`)	Obliga al modelo a devolver campos (intent, fase, análisis), no prosa suelta.
Reglas de negocio	Código propio (Python)	Sin IA — determinístico	Corte 17:30, motorizado, catálogo y precios, handoff a contabilidad/recepción.
Hosting de la app	Render	Docker · 1 CPU · 2 GB RAM · plan Standard	Sirve bot, dashboard, portal y genera PDF con Chromium.

Capa / parte	Plataforma	Motor / modelo	Qué hace
Base de datos	Supabase	PostgreSQL (compute Micro de entrada)	~1.000 clientes, catálogo, pedidos, 40.000+ informes en espejo.
Bandeja y handoff	Chatwoot self-hosted	Chatwoot Community (sin IA propia)	Inbox Telegram/WhatsApp, equipos Operaciones y Contabilidad.
Canal Telegram	Telegram Bot API	Bot de A3 (BotFather)	Transporte de mensajes. Sin costo por mensaje.
Canal WhatsApp	Meta Cloud API + Chatwoot	WhatsApp Business Platform	Código listo; falta cuenta Business de A3 y el número.
Facturación	Alegra	API REST v1 (cuenta real de A3)	Solo borradores. Emisión DIAN la hace A3 en Alegra. `ALEGRA_PRODUCTION=false`.
Resultados de lab	Anarvet	PostgreSQL de Anarvet, función de consulta	Espejo de informes. PDF del informe: Chromium (Playwright), no un modelo de IA.
Dashboard y portal	Misma app en Render	Flask + HTML/JS · sin LLM	Operación interna y consulta de clientes con nombre + NIT.
Avisos técnicos	Telegram (bot aparte)	Bot de alertas, no el de clientes	Avisa si el bot no pudo responder o si hay un 500. Gratis.

Por qué gpt-5.4-mini y no gpt-5.4 “grande”. El bot habla turnos cortos, con catálogo y reglas ya resueltos en código. El modelo grande cuesta varias veces más (aprox. USD 2,50 / millón de tokens de entrada vs USD 0,75 del mini) sin mejora observable para este caso. El identificador en producción es `OPENAI_MODEL=gpt-5.4-mini`.

4. Fichas de cada servicio a contratar

Abajo: qué contratar, plan, costo de mantenimiento y por qué ese plan. Los tres primeros (Render, Supabase, OpenAI) son indispensables el día 1 de producción.

4.1 Render — servidor de la plataforma

CONTRATAR · FACTURA USD

URL DE ALTA	https://render.com
PLAN DE CÓMPUTO	Web Service **Standard** · 1 CPU · 2 GB RAM
COSTO FIJO	**USD 25 / mes**
WORKSPACE	Hobby USD 0 (alcanza). Pro USD 25 solo si A3 quiere más asientos/ancho de banda.
CRON ANARVET	Job que llama al sync cada hora laboral. Se cobra por segundo de ejecución: **centavos al mes**.
ANCHO DE BANDA	Hobby incluye ~5 GB; Pro ~25 GB. El tráfico de un laboratorio B2B suele caber. Extra: USD 0,15 / GB.

El plan Starter (USD 7, 512 MB) **no sirve**: Chromium usa 150–300 MB al armar un PDF y tumba toda la instancia, incluido el bot. Un solo worker (un proceso): el anti-ráfagas del chat vive en memoria.

Región prevista: Oregon (como el blueprint). Dominio: `algo.onrender.com` o el dominio propio de A3 apuntado por DNS.

4.2 Supabase — base de datos

CONTRATAR · FACTURA USD

URL DE ALTA	https://supabase.com
PLAN	**Pro** · organización de A3 · un proyecto
COSTO FIJO	**USD 25 / mes**
COMPUTE	Micro (~1 GB RAM) cubierto por USD 10 de crédito del Pro. Subir a Small (~USD 10 extra) solo si hay saturación.
INCLUYE	8 GB disco, 250 GB egreso, backups diarios 7 días, el proyecto no se pausa.
STORAGE DE PDFS	Bucket privado `lab-results`. 100 GB incluidos en Pro; de más, ~USD 0,021 / GB.

El plan Free pausa el proyecto a la semana de inactividad, limita disco a 500 MB y no tiene backups serios. No es opción de producción. Los ~41.000 informes en espejo ocupan poco frente a 8 GB.

4.3 OpenAI — modelo del bot

CONTRATAR · VARIABLE USD

URL DE ALTA	https://platform.openai.com
MODELO EN PRODUCCIÓN	**gpt-5.4-mini** (no el modelo grande, no GPT-4o)
TARIFA PÚBLICA	USD 0,75 / millón tokens entrada · USD 4,50 / millón salida · caché de entrada USD 0,075 / millón
COSTO ESTIMADO	**USD 40–120 / mes típico**
TOPE RECOMENDADO	Spend limit **USD 150** el primer mes; ajustar con la factura real.
USO	Solo el chat. Dashboard, portal, Alegra y Anarvet no llaman a OpenAI.

Cada turno del bot envía el system prompt, un tramo de historial y el schema JSON, y recibe una respuesta corta. Orden de magnitud: **1 a 3 centavos de dólar por turno**. Un laboratorio B2B (decenas de conversaciones al día, 10–20 turnos por pedido) cae en USD 40–80. Hilos muy largos o pruebas intensivas suben a USD 100–150.

Facturación: pay-as-you-go con tarjeta. Sin cuota fija. El spend limit evita sorpresas.

4.4 Chatwoot — bandeja de conversaciones

CONTRATAR VPS · FACTURA USD/EUR

SOFTWARE	Chatwoot Community, self-hosted (sin cobro por agente)
HOY	Instancia N3: `n3-chatwoot.1hqzy5.easypanel.host`
PARA QUE PAGUE A3	VPS a nombre de A3 (Hetzner, DigitalOcean, o EasyPanel equivalente) y migrar la instancia, *o* dejar el servidor de N3 y refacturar el VPS a costo.
TAMAÑO	4 GB RAM o más (Chatwoot + Postgres + Redis)
COSTO	**USD 15–40 / mes**

Chatwoot Cloud (SaaS por asiento) sale más caro con varios usuarios de operaciones y contabilidad. Self-hosted es el camino actual y el más barato a este volumen. No usa un modelo de IA propio: el “Agent Bot” llama a nuestra app en Render.

4.5 Telegram — canal de clientes

SIN FACTURA

ALTA	@BotFather, a nombre de A3
COSTO	**USD 0**
LÍMITE PRÁCTICO	Sin cobro por mensaje para este uso

Hay un segundo bot solo para avisos técnicos al responsable (caídas, 500). También gratis. No debe ser el mismo bot de clientes, para no mezclar alertas con conversaciones en Chatwoot.

4.6 WhatsApp Business (cuando A3 entregue el número)

META · VARIABLE USD

QUÉ FALTA	Cuenta Meta Business de A3 + WhatsApp Business + número conectado a Chatwoot. El código ya está (migración 031).
MODELO DE COBRO	Por mensaje entregado, según categoría y país del destinatario (Colombia es de los más baratos).
SERVICIO / UTILIDAD CO	Orden de ~USD 0,0008 por mensaje de utilidad; el bot casi solo responde ventanas iniciadas por el cliente.
MARKETING	~USD 0,0125 por mensaje de plantilla de marketing. No hace falta para el bot de recogidas.
ESTIMADO	**USD 5–40 / mes**

Desde octubre de 2026 Meta cobra también mensajes de “servicio” tras un cupo gratuito (~1.000/mes por número). Aun así, el volumen de un laboratorio B2B en Colombia suele quedar bajo. No contratar un BSP extra si Chatwoot habla directo con Cloud API.

4.7 Alegra — facturación (ya de A3)

YA LO PAGAN · COP

CUENTA	A3 LABORATORIO CLINICO VETERINARIO SAS · NIT 900296338
API	Incluida en el plan de Alegra. No hay factura extra “por conectar la plataforma”.
QUÉ HACE LA PLATAFORMA	Crea **borradores**. Nunca emite a la DIAN.
PLANES PÚBLICOS ALEGRA CO	Solo facturación desde ~COP 17.900/mes (Emprendedor) hasta ~COP 179.900 (Plus), según ingresos y usuarios. A3 ya tiene el suyo.

No abrir una segunda cuenta de Alegra para la plataforma. Se usa la cuenta real, con `ALEGRA_PRODUCTION=false` para bloquear emisión desde el software.

4.8 Anarvet — resultados de laboratorio (ya de A3)

YA LO PAGAN

COSTO EXTRA PLATAFORMA	**USD 0**
QUÉ SE NECESITA	Autorizar las IPs de salida de Render en el servidor de Anarvet (whitelist).
USO	Consulta de informes (solo lectura) y publicación de PDF al portal.

4.9 Dominio y DNS

OPCIONAL PERO RECOMENDABLE

PARA QUÉ	URL estable del dashboard y del portal (`plataforma.a3….co`)
COSTO	**USD 10–35 / año**
SSL	Lo emite Render, sin costo extra.

Mientras tanto se puede operar con `*.onrender.com`. El dominio es imagen y permanencia, no un requisito técnico del bot.

4.10 GitHub — código

USD 0 O BAJO

El repo puede seguir donde está. GitHub Free cubre privado. Si A3 quiere organización propia con varios asientos de administración: GitHub Team ~USD 4 / usuario / mes. No es costo de “tener la plataforma levantada”.

5. Detalle del modelo de IA

Parámetro	Valor
Proveedor	OpenAI (platform.openai.com), organización a nombre de A3
Modelo	`gpt-5.4-mini`
Entrada	USD 0,75 por 1.000.000 de tokens
Entrada en caché	USD 0,075 por 1.000.000 (el prompt de sistema se repite y puede abaratar)
Salida	USD 4,50 por 1.000.000 de tokens
Modo	Chat Completions + Structured Outputs (JSON schema)
Qué no usa	Assistants API, fine-tuning, GPT Store, voz, visión, batch (el chat tiene que ser en vivo)
Otras IAs	Ninguna. No hay Claude, Gemini ni modelo local en producción.

Ejemplo de caja de OpenAI (órdenes de magnitud)

Volumen mensual	Turnos aprox.	Costo OpenAI
Uso bajo (arranque / pocas clínicas activas en chat)	1.500–3.000	USD 20–50
Uso esperado (operación B2B diaria)	4.000–8.000	USD 50–100
Pico (campaña, WhatsApp + Telegram, pruebas)	10.000+	USD 120–180

Un “turno” es un mensaje del cliente que el bot procesa. Un pedido completo de recogida suele ser entre 8 y 20 turnos.

6. Tabla consolidada de mantenimiento mensual

Servicio	¿A3 lo contrata?	Tipo	Bajo	Esperado	Techo 1.er mes
Render Standard	Sí	Fijo	25	25	25
Render workspace Pro (opcional)	Solo si quieren equipo/ancho extra	Fijo	0	0	25
Supabase Pro	Sí	Fijo	25	25	25
OpenAI gpt-5.4-mini	Sí	Variable	40	80	150
Chatwoot en VPS	Sí (o refactura N3)	Fijo	15	25	40
Dominio (prorrateo)	Recomendado	Fijo bajo	1	2	3
WhatsApp Cloud API	Cuando exista el número	Variable	0	15	40
Telegram	Alta, sin pago	—	0	0	0
Alegra	Ya lo tienen	Ya en COP	No suma a este presupuesto USD		
Anarvet	Ya lo tienen	—	0	0	0
ngrok	No en producción	—	0	0	0
Total USD / mes (sin WhatsApp)			**106**	**157**	**268**
Total USD / mes (con WhatsApp)			**106**	**172**	**308**

Cifras en USD. Equivalente orientativo a COP 4.000/USD:

PISO (SIN WHATSAPP)	CAJA ESPERADA	RESERVAR EL 1.ER MES
~USD 110	**~USD 160**	**USD 250–300**
~COP 440.000 / mes	~COP 640.000 / mes	~COP 1.000.000 · luego ajustar

Cómo leer el “esperado”. Es el escenario de operación real: Render + Supabase + VPS de Chatwoot + un uso normal del bot. No incluye el plan Alegra (ya sale por otro centro de costo) ni Anarvet.

7. Qué no hay que contratar

- Render Scale / Enterprise, ni instancia Pro de 4 GB, salvo que el PDF y el tráfico lo pidan después.
- Supabase Team (USD 599) o Enterprise.
- OpenAI gpt-5.4 (modelo grande), fine-tuning, ni un segundo proveedor de IA.
- Chatwoot Cloud por asiento, si ya self-hostean.
- ngrok de pago (solo desarrollo; producción es Render).
- Postgres adicional en Render: la base ya está en Supabase.
- BSP de WhatsApp (360dialog, Twilio, etc.) si Meta Cloud API + Chatwoot alcanza.
- Nueva cuenta de Alegra o de Anarvet.

8. Checklist de altas (titular A3)

1. **Correo y tarjeta.** Un correo tipo `plataforma@…` o el de administración, y una tarjeta corporativa. Mismo titular en todas las cuentas.
2. **Render.** Crear workspace → invitar a N3 como colaborador → N3 despliega el blueprint (Docker Standard, auto-deploy apagado).
3. **Supabase.** Org Pro → un proyecto → invitar a N3. No usar el proyecto Free de desarrollo como producción si se puede evitar.
4. **OpenAI.** Organización A3 → API key solo para producción → spend limit USD 150 → N3 carga la key en Render. Nunca una key personal.
5. **Chatwoot / VPS.** Decidir: VPS nuevo a nombre de A3 (migración) o dejar EasyPanel de N3 y que A3 pague ese servidor.
6. **Telegram.** Bot de clientes + bot de alertas, ambos de A3.
7. **Alegra y Anarvet.** No alta nueva: entregar token API (Alegra) y pedir whitelist de IPs de Render (Anarvet).
8. **Dominio.** Comprar y apuntar CNAME a Render cuando tengan el nombre.
9. **WhatsApp.** Cuando A3 tenga Business: conectar el número al inbox de Chatwoot. No cancelar LiveConnect hasta probar la cadena.

9. Costos que este PDF no cubre

- Honorarios de desarrollo, soporte o mejoras de N3 (es otro contrato).
- Horas de personal de A3 (recepción, motorizados, contabilidad).
- Internet, PCs, celulares, impresoras.
- Plan Alegra y contrato Anarvet (ya existen).
- Campañas de marketing por WhatsApp (plantillas de marketing).
- Impuestos y spread de la tarjeta al pagar en USD.

10. Supuestos y vigencia

- Precios de Render, Supabase, OpenAI y Meta consultados en septiembre de 2026. Los proveedores los cambian sin aviso a este documento.
- COP 4.000 / USD es una regla de bolsillo, no TRM oficial.
- Volumen de chat: laboratorio B2B en Bogotá, no un bot masivo de consumidor final.
- Un servicio web en Render, un proyecto Supabase, una instancia Chatwoot, un modelo OpenAI.

- WhatsApp no entra al costo “día 1” hasta que A3 entregue número y cuenta Business.

> **Revisión sugerida:** a los 30 días de producción, bajar las tres facturas (Render, Supabase, OpenAI) y ajustar el techo de OpenAI. Ahí el “esperado” deja de ser estimado y pasa a ser histórico.
